

Plantilla presentación

DIAPOSITIVA 1

El núcleo técnico de nuestro sistema de recomendación se basa principalmente en un modelo en 2 fases:

Fase 1: Modelo de clasificación

Hemos entrenado un modelo XGBoost para predecir la compra o no compra para un par artículo-usuario

Fase 2: Recomendación según probabilidades

En esta fase realizamos predicciones con el modelo anterior sobre un catálogo de artículos. Las recomendaciones finales serán las Top12 más probables para nuestro caso.

DIAPOSITIVA 2

En la creación de este modelo de recomendación hemos considerado tres procesos que son fundamentales para el objetivo:

1. Feature Engineering: Además las features de usuario y artículo provenientes de las transacciones hemos imputado en el modelo otras features importantes a nivel de usuario y artículo y además features cruzadas que relacionan artículo-usuario
2. Generación de negativos: Además de las compras de cada usuario debemos imputar negativos al modelo, cosas que no compró. Diferenciamos entre dos técnicas:
 - Easy negatives: negativos generados al azar o por popularidad. Ayuda al modelo a discriminar atributos generales que el usuario no compraría ese artículo.
 - Hard negatives: negativos con artículos similares a lo que compró. Ayuda al modelo a aprender atributos mucho más finos.
3. Generación de candidatos: Para la Fase 2 del modelo, necesitamos generar un catálogo de artículos para generar las predicciones y luego el output final. Para ello también hemos probado dos técnicas
 - Pool genérico de los más populares: Para el buen funcionamiento del modelo necesitamos pasarle una grandísima cantidad de artículos
 - Pool personalizado: Con distintas técnicas generamos candidatos similares a lo que ha comprado el usuario.
4. Modelos auxiliares: Durante el proceso hemos probado otro tipo de modelos, que por sí mismos no nos han dado resultados pero nos han sido de gran ayuda en estos 3 procesos

DIAPOSITIVA 3

En esta primera gráfica queremos mostrar cómo evolucionó nuestro proceso de optimización con Optuna.

Al principio, como ven en los puntos verdes de la zona inferior, la gran mayoría de nuestros experimentos con candidatos personalizados daban resultados muy bajos. En ese momento podríamos haber pensado que la generación de candidatos no funcionaba o no servía.

Sin embargo, tras iterar, mejorar esta generación tunear los hiperparámetros, logramos subir progresivamente la curva hasta alcanzar nuestro mejor run de XGBoost con un MAP@12 de 0.0242 y un 5.9% de aciertos directos.

La clave estuvo en no descartar la estrategia híbrida, y la razón de por qué funcionó la vemos en la siguiente diapositiva.

DIAPOSITIVA 4

Por qué sabíamos que íbamos por el buen camino incluso cuando el MAP@12 inicial era bajo? Por el Hit Rate Relativo.

Aun con métricas globales modestas al inicio, veíamos que el modelo lograba un 18% a 20% de Hit Relativo. Es decir, de la pequeña selección de candidatos personalizados que le entregábamos, el modelo era capaz de convertir una quinta parte.

Eso nos demostró que la generación de candidatos sí era la estrategia correcta y que el modelo realmente aprendía la afinidad del cliente. Porque cuando le pasábamos al modelo productos afines al usuario tenía una gran conversión frente a la generación genérica de candidatos, donde el modelo se perdía con tanto ruido. Además de perder la personalización y el gran costo computacional.

Con todo esto podemos concluir que la generación de candidatos es claramente la estrategia correcta.